Bayes' sætning – at lære af data

Hvor sandsynligt er det, at du er syg, når testen er positiv? Skal du skifte dør i Monty Hall-spillet? Hvor skæv er en mønt efter 20 kast? Alle tre spørgsmål besvares af en formel, som en engelsk præst skrev ned omkring 1760, og som i dag bruges i alt fra spamfiltre og selvkørende biler til eftersøgningen af forsvundne fly og fortolkningen af gravitationsbølger. Bayes' sætning fortæller, hvordan man bør ændre sin overbevisning, når man får nye data.

Pastor Bayes og Laplace

Thomas Bayes (ca. 1701–1761) var præst for en frikirkemenighed i Tunbridge Wells i Kent og amatørmatematiker. Efter hans død fandt vennen Richard Price et manuskript blandt hans papirer og fik det trykt i Royal Societys *Philosophical Transactions* i 1763 under titlen *An Essay towards solving a Problem in the Doctrine of Chances*. Bayes spurgte: Hvis en begivenhed er indtruffet h gange og udeblevet t gange, hvad kan vi så sige om dens ukendte sandsynlighed? Uafhængigt af ham udviklede Pierre-Simon Laplace fra 1774 den „omvendte sandsynlighed" til et generelt redskab og brugte det bl.a. til at vise, at der fødes flere drenge end piger i Paris, og til at vurdere usikkerheden på planeternes masser.

Sætningen

Fra definitionen af betinget sandsynlighed er $P(A \cap B) = P(A)\,P(B \mid A) = P(B)\,P(A \mid B)$. Divider med $P(B)$:

$$P(A \mid B) = \frac{P(B \mid A)\,P(A)}{P(B)}, \qquad P(B) = P(B \mid A)\,P(A) + P(B \mid \bar{A})\,P(\bar{A})$$

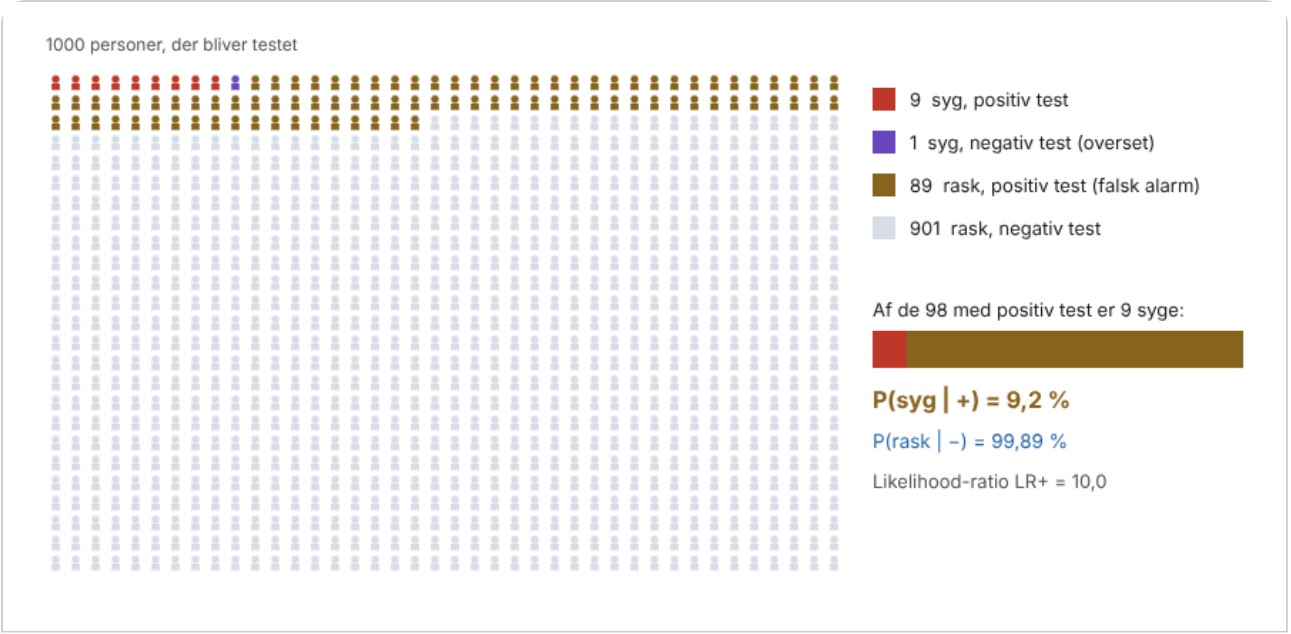
Tænk på A som en hypotese og B som data. Så er

- $P(A)$ – **forhåndssandsynligheden** (*prior*): hvad vi troede før data;
- $P(B \mid A)$ – **likelihood**: hvor godt hypotesen forudsiger de data, vi så;
- $P(A \mid B)$ – **efterfølgende sandsynlighed** (*posterior*): hvad vi bør tro bagefter.

Sætningen er ren matematik og helt ukontroversiel. Diskussionen mellem „bayesianere" og „frekventister" gennem det 20. århundrede handlede om, hvorvidt man må tillægge en hypotese en sandsynlighed – og hvor forhåndssandsynligheden skal komme fra.

Den positive test

En sygdom har en forekomst (prævalens) på 1 %. En test opdager 90 % af de syge (*sensitiviteten*) og er negativ hos 91 % af de raske (*specificiteten*). Du tester positivt. Hvor sandsynligt er det, at du er syg? Da psykologen Gerd Gigerenzer stillede netop dette spørgsmål til 160 gynækologer, svarede næsten halvdelen „9 ud af 10“, og kun omkring hver femte valgte det rigtige svar: cirka 1 ud af 10.



Odds-formen – den nemmeste udgave

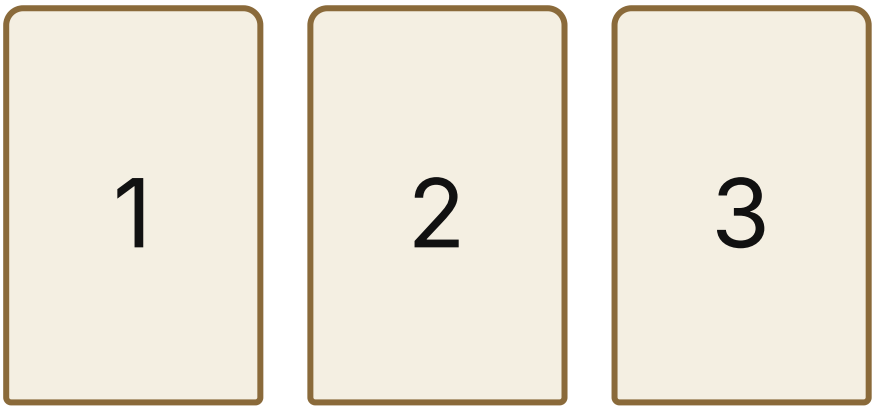
Skriv sandsynligheder som odds, $O = P/(1-P)$. Så bliver Bayes' sætning en simpel multiplikation:

$$O(A \mid B) = O(A) \times \frac{P(B \mid A)}{P(B \mid \bar{A})}$$

Brøken er *likelihood-ratioen*: hvor mange gange mere sandsynlige data er, hvis hypotesen er sand, end hvis den er falsk. For testen ovenfor er den $0{,}90/0{,}09 = 10$. Odds før er 1 : 99; odds efter er 10 : 99, dvs. en sandsynlighed på $10/109 \approx 9\ \%$. Hver ny uafhængig observation ganger blot oddsene med sin likelihood-ratio. Alan Turing og I.J. Good brugte netop denne form, målt i logaritmiske enheder („deciban“), til at bryde den tyske Enigma-kode på Bletchley Park under Anden Verdenskrig.

Monty Hall-problemet

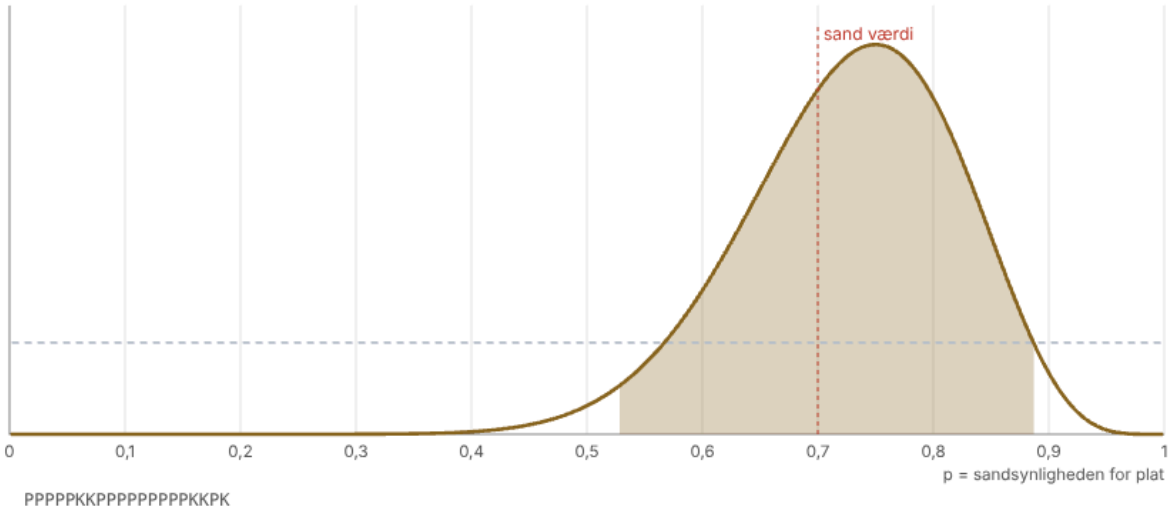
I et amerikansk tv-quizprogram, *Let's Make a Deal* med værten Monty Hall, skal du vælge én af tre døre. Bag én står en bil, bag de to andre en ged. Når du har valgt, åbner værten – som ved, hvor bilen står – en af de andre døre og viser en ged. Han tilbyder dig at skifte. Skal du? Da Marilyn vos Savant i 1990 skrev i bladet *Parade*, at man skal skifte, fik hun tusindvis af breve, også fra matematikere, der mente, hun tog fejl. Hun havde ret: at skifte vinder med sandsynlighed $\mathbf{2/3}$.



Bliv: 0 gevinster af 0 (–) · Skift: 0 af 0 (–)

Bayesiansk opdatering – hvor skæv er mønten?

Bayes' oprindelige problem: en mønt viser plat med en ukendt sandsynlighed p. Vi beskriver vores usikkerhed om p med en fordeling. Efter h plat og t krone er den efterfølgende fordeling proportional med forhåndsfordelingen gange likelihood $p^h(1-p)^t$. Starter man med en betafordeling $\mathrm{Beta}(a, b)$, ender man med $\mathrm{Beta}(a+h,\, b+t)$. Med ligefordelt forhåndsviden ($a = b = 1$) er det bedste bud på næste kast Laplaces *successionsregel* $(h+1)/(n+2)$.



Anklagerens fejlslutning

At forveksle $P(\text{data} \mid \text{uskyldig})$ med $P(\text{uskyldig} \mid \text{data})$ kaldes *anklagerens fejlslutning*. Hvis et DNA-spor matcher én ud af en million, og byen har fem millioner indbyggere, vil omkring fem uskyldige også matche – så et match alene gør ikke sandsynligheden for skyld 999 999 ud af en million. I den britiske sag mod Sally Clark (dømt 1999, frifundet ved anke 2003) sagde en ekspertvidne, at sandsynligheden for to vuggedødsfald i samme familie var 1 ud af 73 millioner. Tallet var forkert beregnet (det antog uafhængighed), og det blev præsenteret, som om det var sandsynligheden for, at hun var uskyldig. Royal Statistical Society protesterede offentligt i 2001.

Bayes i praksis

Spamfiltre

Et filter lærer, hvor ofte hvert ord optræder i spam og i almindelig post, og kombinerer ordenes likelihood-ratioer til en sandsynlighed for spam. Paul Graham gjorde metoden populær i 2002.

Eftersøgning

Ubåden USS Scorpion (1968) og vraget af Air France-flyet 447, der styrtede i Atlanterhavet i 2009, blev fundet ved bayesiansk eftersøgning: havbunden deles i felter med en sandsynlighed for vraget, som opdateres, hver gang et felt er gennemsøgt uden fund. AF447 blev fundet i april 2011 efter en ny analyse.

Fysik og astronomi

Masserne af de sorte huller bag gravitationsbølger, kosmologiens parametre fra Planck-satellitten og exoplaneters baner bestemmes med bayesianske metoder, hvor man beregner hele fordelingen af parameterværdier, der er forenelige med data.

Hjernen

En indflydelsesrig teori i neurovidenskaben siger, at sanserne fungerer bayesiansk: hjernen kombinerer forventning (prior) med sanseindtryk (likelihood). Mange synsbedrag kan forklares sådan – fx at vi antager, at lyset kommer oppefra.

Læs mere

- Sharon Bertsch McGrayne: *The Theory That Would Not Die* (Yale 2011) – Bayes' sætnings historie fra Enigma til ubådsjagt
- Gerd Gigerenzer: *Reckoning with Risk* (Penguin 2003)
- David Spiegelhalter: *The Art of Statistics* (Pelican 2019)
- E.T. Jaynes: *Probability Theory – The Logic of Science* (Cambridge 2003) – for den matematisk interesserede
- Siderne om krydstabeller og trædiagrammer og sandsynlighedsregning

mhgfysik.dk · Michael H. Grant, lektor emeritus i fysik & matematik · Indholdet må genbruges under CC BY 4.0 med kildeangivelse. · Til forsiden · Interaktive figurer: mhgfysik.dk/bayes.html