Krydstabeller, Venn- og trædiagrammer – betinget sandsynlighed i praksis

Betingede sandsynligheder er overalt: chancen for at overleve en skibskatastrofe givet køn og klasse, for at en vaccine virker, for at en positiv test betyder sygdom. De tre klassiske redskaber til at holde styr på dem er krydstabellen, Venn-diagrammet og trædiagrammet. Her kan du selv indtaste tal, vende træer om – og møde Simpsons paradoks, hvor en behandling er bedst i hver eneste gruppe, men dårligst samlet.

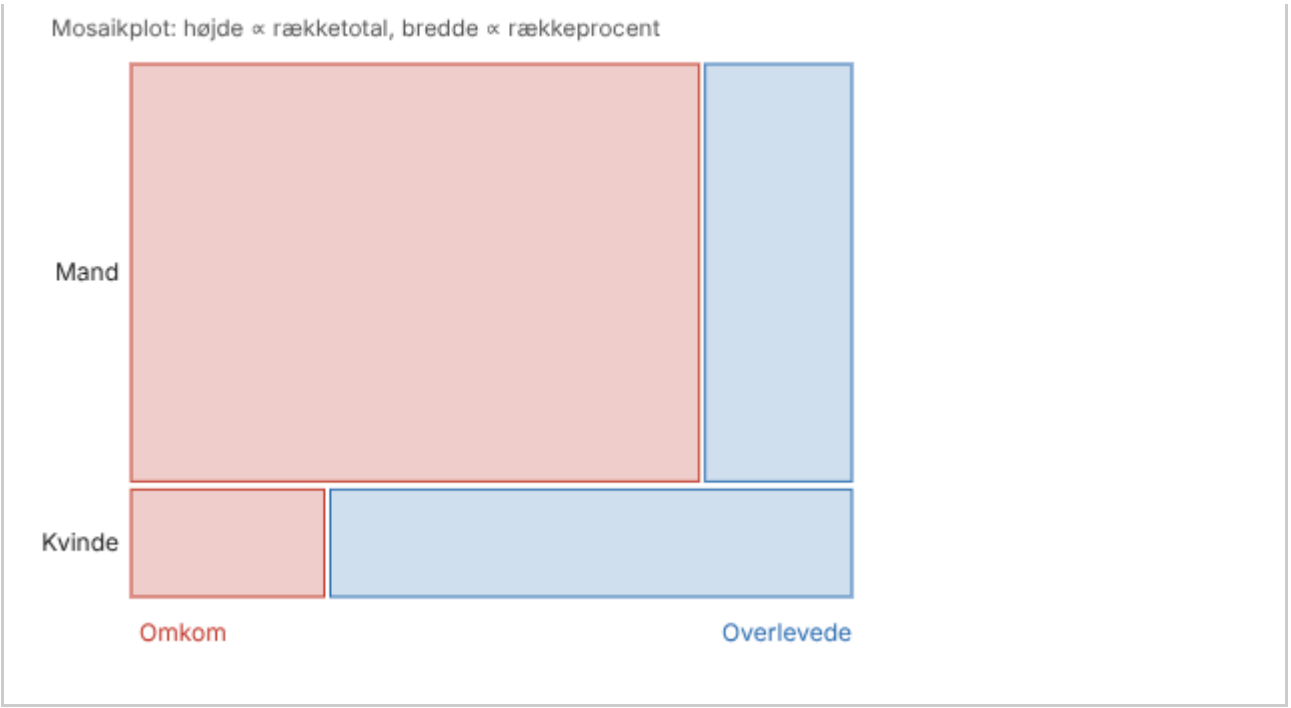
Krydstabeller

En *krydstabel* (kontingenstabel – det engelske *contingency table* blev indført af Karl Pearson i 1904) tæller, hvor mange der falder i hver kombination af to kategoriske variable. Rækker og søjler summeres til *marginaler*. Fra tabellen kan man aflæse tre slags sandsynligheder:

- **Simultane** sandsynligheder: celle / total, fx $P(\text{mand} \cap \text{omkom})$.
- **Marginale** sandsynligheder: række- eller søjletotal / total, fx $P(\text{omkom})$.
- **Betingede** sandsynligheder: celle / række- eller søjletotal, fx $P(\text{omkom} \mid \text{mand})$. Det er rækkeprocenterne (eller søjleprocenterne).

Det klassiske eksempel er Titanic, der sank natten mellem den 14. og 15. april 1912. Af de 2201 om bord (passagerer og besætning) overlevede 711. Princippet „kvinder og børn først" ses tydeligt i tabellen.

	Omkom	Overlevede	I alt
Mand	1364	367	1.731
Kvinde	126	344	470
I alt	1.490	711	2.201



Risiko, odds og uafhængighed

Lad p_1 og p_2 være sandsynligheden for udfaldet i de to rækker. Så er

$$\text{relativ risiko} = \frac{p_1}{p_2}, \qquad \text{odds-ratio} = \frac{p_1/(1-p_1)}{p_2/(1-p_2)} = \frac{ad}{bc}$$

hvor a, b, c, d er de fire celler. Hvis rækkevariablen og søjlevariablen er *uafhængige*, er rækkeprocenterne ens, og hver celle forventes at indeholde $\text{rækketotal} \times \text{søjletotal}/\text{total}$. χ^2-testen (se statistiske fordelinger) måler afstanden mellem de observerede og de forventede antal; for en 2×2-tabel har den 1 frihedsgrad. Men husk: en sammenhæng i en krydstabel beviser ikke årsag. Det kræver et lodtrækningsforsøg som vaccineforsøget, hvor kun behandlingen adskiller grupperne.

Venn-diagrammer

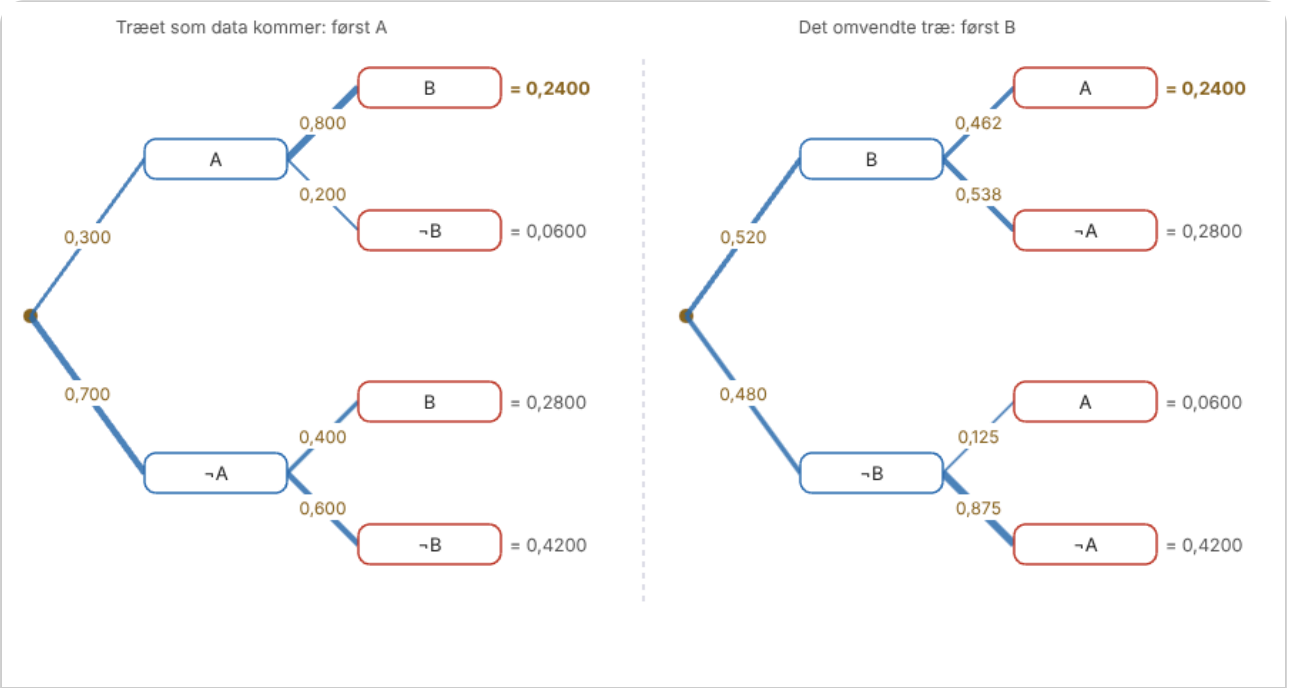
Et Venn-diagram viser de samme fire celler som en 2×2-tabel: $A \cap B$, $A \cap \bar{B}$, $\bar{A} \cap B$ og $\bar{A} \cap \bar{B}$. Det er godt til at se fællesmængder og additionsreglen, men dårligere til betingede sandsynligheder, fordi cirklernes areal sjældent er tegnet i rigtig størrelse. På siden om sandsynlighedsregning er der et interaktivt, arealtro Venn-diagram, og på siden om logik kan du skravere områder for vilkårlige udtryk i tre mængder.

Trædiagrammer

Et *trædiagram* viser et forsøg i flere trin. Hver gren har en betinget sandsynlighed, og sandsynligheden for en hel vej fra roden til et blad er produktet af grenenes sandsynligheder (*multiplikationsreglen*):

$$P(A \cap B) = P(A)\,P(B \mid A)$$

Grenene fra hver knude summer til 1, og bladene summer tilsammen til 1. Træet passer naturligt til den rækkefølge, tingene sker i: først er man syg eller rask, derefter bliver testen positiv eller negativ. Men ofte vil man vide det omvendte – og så må træet vendes.



Loven om total sandsynlighed og Bayes' sætning

Sandsynligheden for B fås ved at lægge alle veje til B sammen:

$$P(B) = P(A)\,P(B \mid A) + P(\bar{A})\,P(B \mid \bar{A})$$

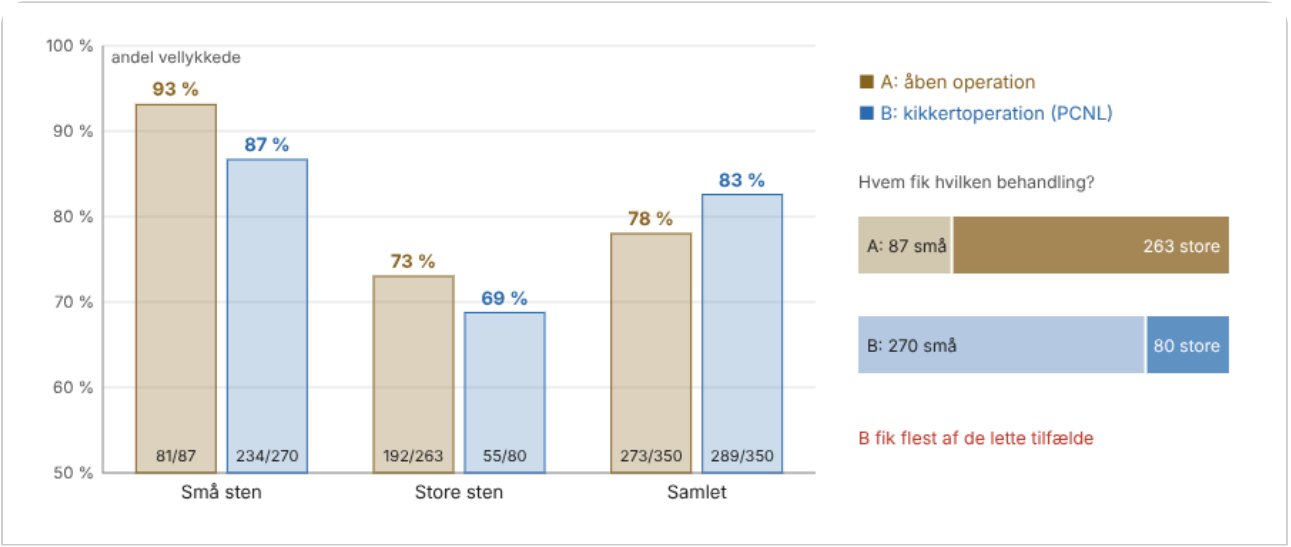
og at vende træet om er Bayes' sætning:

$$P(A \mid B) = \frac{P(A)\,P(B \mid A)}{P(B)}$$

Den har sin egen side: Bayes' sætning. En god tommelfingerregel fra psykologen Gerd Gigerenzer: regn i *naturlige frekvenser* – „ud af 1000 personer er 10 syge; 9 af dem tester positivt; af de 990 raske tester 89 positivt" – så bliver svaret $9/(9+89) \approx 9\,\%$ næsten selvindlysende. Krydstabellen er netop naturlige frekvenser.

Simpsons paradoks

En sammenhæng, der gælder i hver eneste delgruppe, kan vende om, når grupperne slås sammen. Fænomenet blev beskrevet af Edward Simpson i 1951 (og før ham af Udny Yule i 1903). Et berømt eksempel er en britisk undersøgelse af behandling af nyresten (Charig m.fl., *British Medical Journal* 1986): åben operation (A) havde højere succesrate end kikkertoperation (B) både for små og for store sten – men lavere samlet.



Gode råd

Spørg: procent af hvad?

Rækkeprocent og søjleprocent besvarer forskellige spørgsmål. „90 % af de syge tester positivt" er ikke det samme som „90 % af de positive er syge".

Tæl, før du regner

Omskriv sandsynligheder til antal i en tænkt gruppe på fx 1000 eller 100 000 personer. Så bliver krydstabel, træ og Bayes til simpel optælling.

Led efter confoundere

Før man konkluderer, at A fører til B, bør man spørge, om en tredje variabel påvirker begge. Lodtrækning (randomisering) er den sikreste kur.

Absolut og relativ risiko

„Halveret risiko" lyder af meget, men fra 2 ud af 10 000 til 1 ud af 10 000 er en absolut forskel på 1 ud af 10 000. Angiv begge dele.

Læs mere

- Gerd Gigerenzer: *Reckoning with Risk – Learning to Live with Uncertainty* (Penguin 2003)
- David Spiegelhalter: *The Art of Statistics – Learning from Data* (Pelican 2019)
- Judea Pearl og Dana Mackenzie: *The Book of Why* (Basic Books 2018) – om årsager, confoundere og Simpsons paradoks
- Siderne om sandsynlighedsregning og Bayes' sætning

mhgfysik.dk · Michael H. Grant, lektor emeritus i fysik & matematik · Indholdet må genbruges under CC BY 4.0 med kildeangivelse. · Til forsiden · Interaktive figurer: mhgfysik.dk/krydstabeller-og-traediagrammer.html