Statistiske fordelinger – fra terningkast til atomkerner

Ét terningkast er uforudsigeligt, men tusind terningkast er det ikke. Det samme gælder et radioaktivt henfald, en molekyles fart, en målefejl eller et barns højde. Sandsynlighedsregningen beskriver, hvordan tilfældige udfald fordeler sig, og nogle få fordelinger går igen overalt i naturen og samfundet: binomialfordelingen, Poisson-fordelingen, eksponentialfordelingen og frem for alt normalfordelingen. Her er de med eksempler og interaktive figurer – og med de redskaber, der bruges til at drage konklusioner fra data.

Tilfældighed og fordelinger

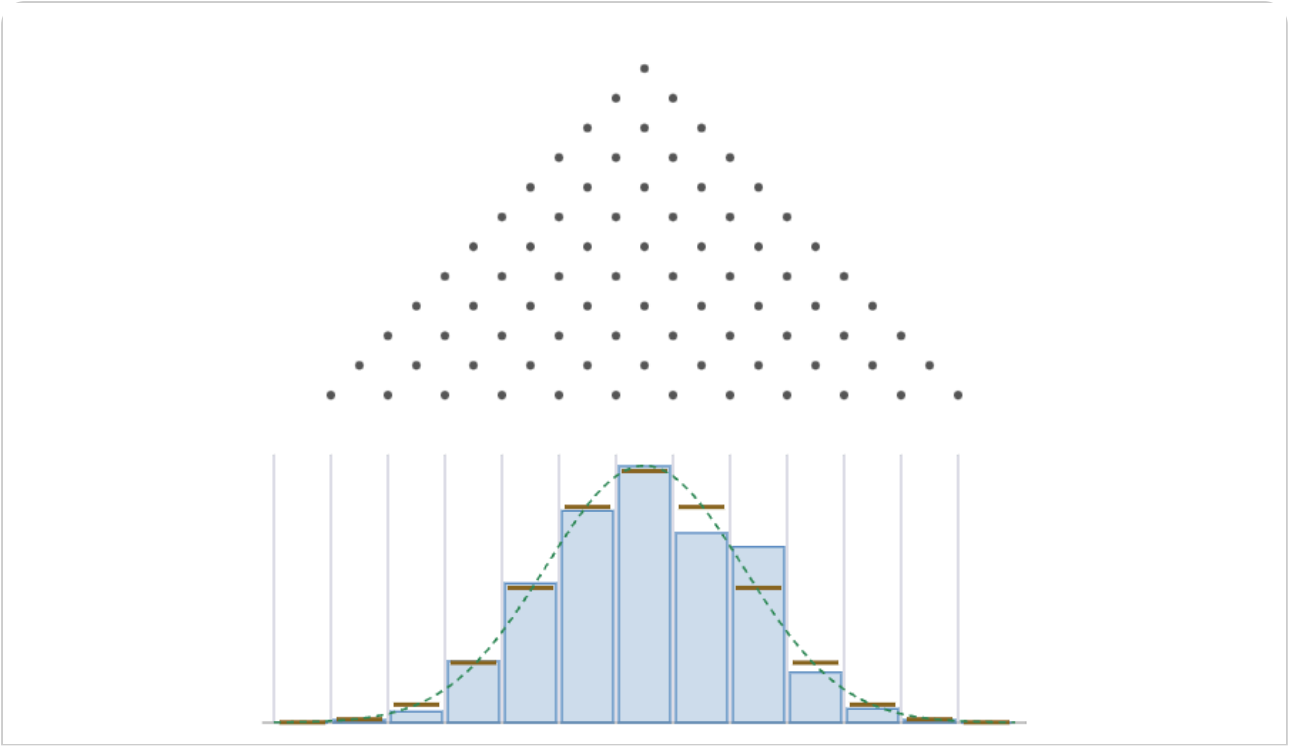
En *stokastisk variabel* X er et tal, der afhænger af et tilfældigt udfald: antal øjne på en terning, antal henfald i et sekund, en persons højde. Fordelingen fortæller, hvor sandsynlige de forskellige værdier er. For en *diskret* variabel angiver man sandsynligheden $P(X = k)$ for hver værdi; for en *kontinuert* variabel en tæthedsfunktion $f(x)$, hvor sandsynligheden for et interval er arealet under kurven:

$$P(a < X < b) = \int_a^b f(x)\,dx, \qquad \int_{-\infty}^{\infty} f(x)\,dx = 1$$

To tal beskriver det meste: *middelværdien* (forventningsværdien) μ, der fortæller, hvor fordelingen ligger, og *spredningen* σ (standardafvigelsen), der fortæller, hvor bred den er. Variansen er σ^2:

$$\mu = E(X) = \sum_k k\,P(X = k), \qquad \sigma^2 = E\big[(X-\mu)^2\big] = E(X^2) - \mu^2$$

Sandsynlighedsregningen begyndte med hasardspil: Pascal og Fermat skrev sammen om terningspil i 1654, og Jakob Bernoullis *Ars Conjectandi* (1713) beviste den første udgave af de store tals lov. Francis Galton byggede i 1870'erne et bræt med søm, hvor kugler hopper til højre eller venstre ved hvert søm – en mekanisk maskine, der viser, hvordan orden opstår af tilfældighed.

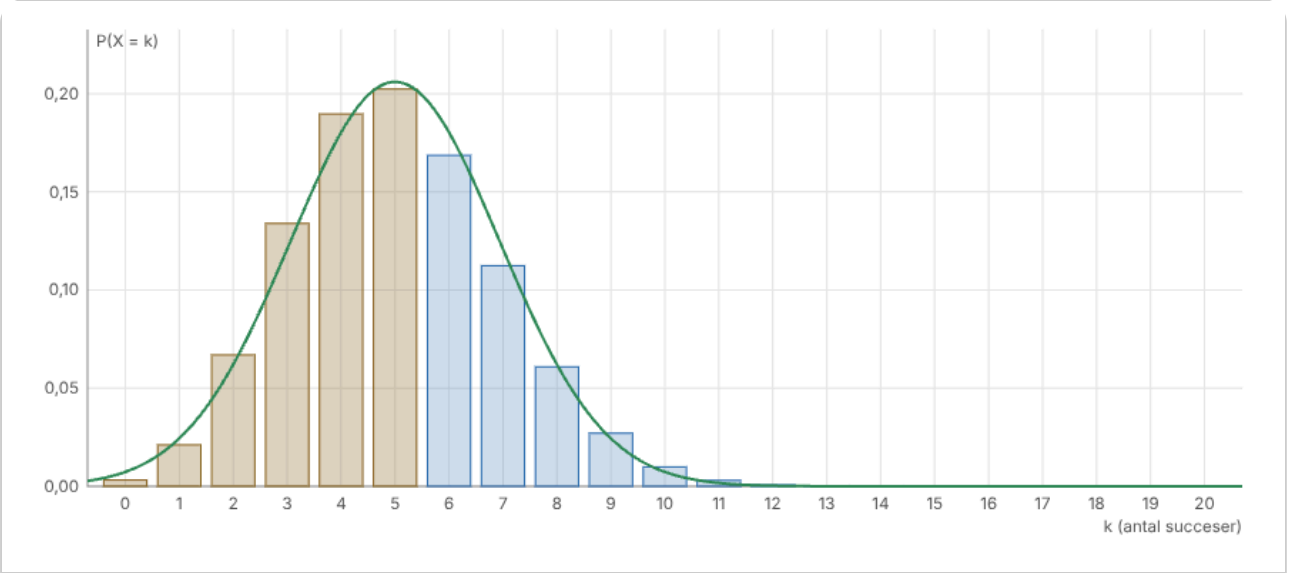


Binomialfordelingen

Gentag et forsøg n gange uafhængigt af hinanden, hvor hvert forsøg lykkes med sandsynligheden p. Antallet af succeser X er *binomialfordelt*:

$$P(X=k)=\binom{n}{k}p^k(1-p)^{n-k},\qquad \mu=np,\qquad \sigma=\sqrt{np(1-p)}$$

Binomialkoefficienten $\binom{n}{k}=\dfrac{n!}{k!\,(n-k)!}$ tæller, på hvor mange måder de k succeser kan placeres blandt de n forsøg – det er tallene i Pascals trekant, og det er antallet af veje til hver bås på Galtons bræt. Eksempler: antal plat i 10 møntkast, antal rigtige svar ved at gætte i en multiple choice-prøve, antal drenge blandt 100 nyfødte (andelen af drenge er omkring 51,4 %), antal defekte varer i en stikprøve.



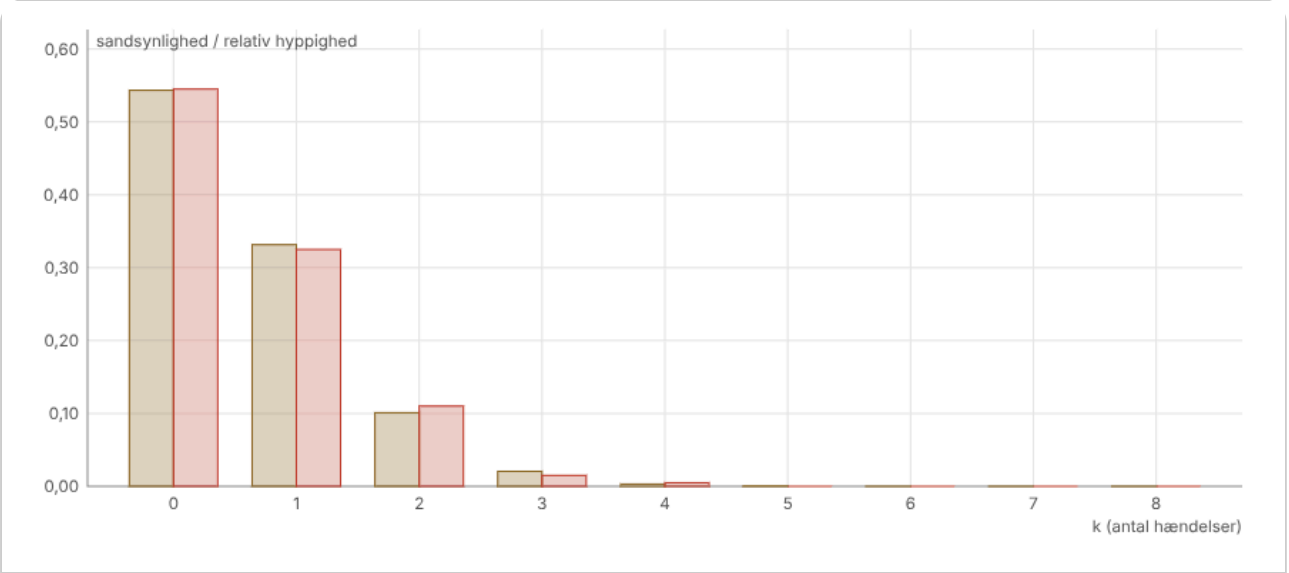
Poisson-fordelingen – de sjældne hændelsers lov

Hvis n er meget stor og p meget lille, mens $np = \lambda$ holdes fast, går binomialfordelingen over i *Poisson-fordelingen*, som Siméon Denis Poisson udledte i 1837:

$$P(X = k) = \frac{\lambda^k}{k!}\, e^{-\lambda}, \qquad \mu = \lambda, \qquad \sigma^2 = \lambda$$

Den beskriver antallet af hændelser i et tidsrum eller et område, når hændelserne indtræffer uafhængigt af hinanden med en fast gennemsnitlig rate: henfald i en radioaktiv kilde, fotoner i en detektor, stjerneskud pr. time, opkald til en vagtcentral, mutationer i et gen. Fordelingens kendetegn er, at variansen er lig med middelværdien – derfor er den relative usikkerhed på en tælling $\sqrt{N}/N = 1/\sqrt{N}$. Tæller man 100 henfald, er usikkerheden 10 %; tæller man 10 000, er den 1 %.

To klassiske datasæt viser loven i virkeligheden. Den russisk-tyske statistiker Ladislaus von Bortkiewicz talte i 1898 antallet af soldater i den prøjsiske hær, der blev dræbt af hestespark: 10 armékorps i 20 år, i alt 200 korps-år. Ernest Rutherford og Hans Geiger talte i 1910 α-partikler fra en poloniumkilde i 2608 tidsintervaller på 7,5 sekunder.

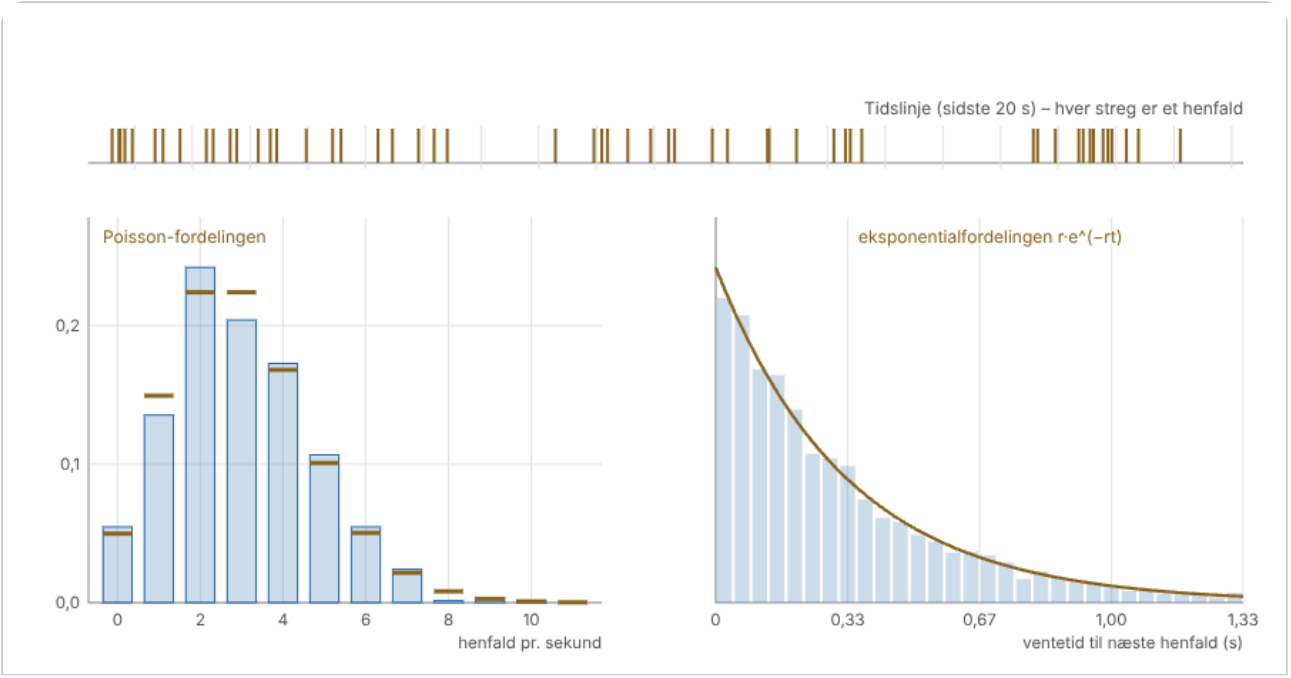


Ventetider og eksponentialfordelingen

Hændelser, der indtræffer tilfældigt og uafhængigt med raten r, kaldes en *Poisson-proces*. Antallet i et tidsrum t er Poisson-fordelt med $\lambda = rt$, og ventetiden T til næste hændelse er *eksponentialfordelt*:

$$f(t) = r\,e^{-rt}, \qquad P(T > t) = e^{-rt}, \qquad E(T) = \frac{1}{r}$$

Eksponentialfordelingen er *hukommelsesløs*: Har man allerede ventet 10 sekunder, er den forventede resterende ventetid stadig $1/r$. En atomkerne bliver ikke „gammel" – den har samme sandsynlighed for at henfalde i det næste sekund, uanset hvor længe den har eksisteret. Derfor henfalder en mængde kerner eksponentielt, $N(t) = N_0 e^{-rt}$, med halveringstiden $T_{1/2} = \ln 2 / r$. Samme fordeling beskriver tiden mellem kundeankomster i en kø og levetiden for elektroniske komponenter uden slid.



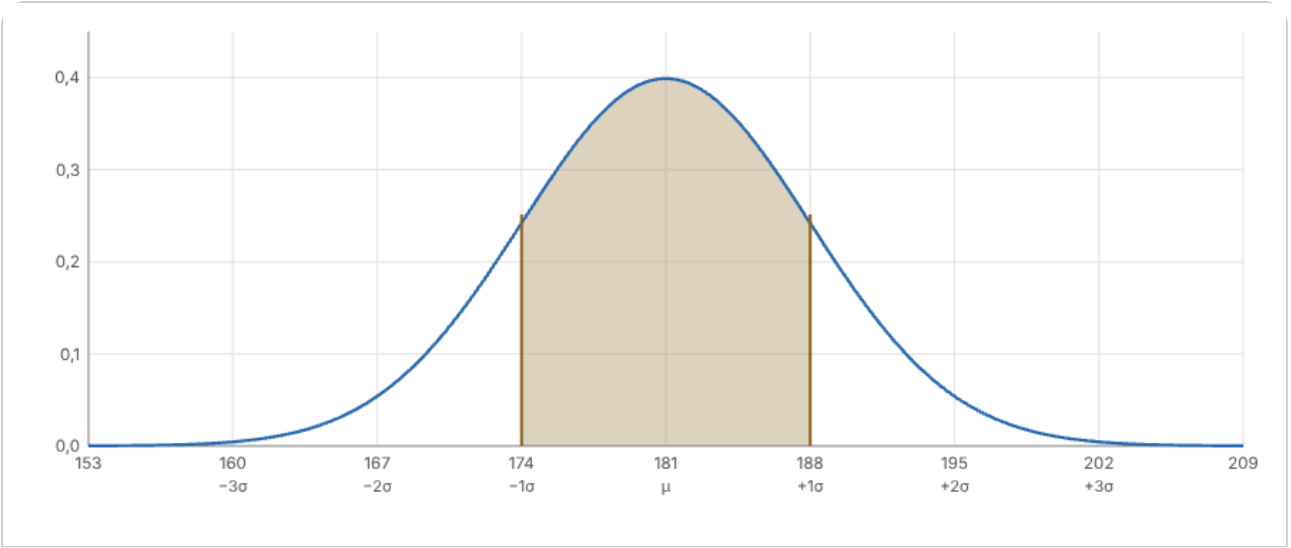
Normalfordelingen

Abraham de Moivre opdagede i 1733, at binomialfordelingen for store n nærmer sig en bestemt klokkeformet kurve. Carl Friedrich Gauss brugte den i 1809 til at beskrive målefejl i astronomien, og Pierre-Simon Laplace viste i 1810, hvorfor den optræder så ofte (se den centrale grænseværdisætning nedenfor). Tætheden er

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

Alle normalfordelinger er den samme kurve, bare flyttet og strakt. Derfor regner man i *standardiserede* enheder $z = (x-\mu)/\sigma$ og husker tommelfingerreglen:

Interval	Andel inden for	Andel uden for
μ ± 1σ	68,27 %	ca. 1 ud af 3
μ ± 2σ	95,45 %	ca. 1 ud af 22
μ ± 3σ	99,73 %	ca. 1 ud af 370
μ ± 5σ	99,99994 %	ca. 1 ud af 1,7 mio.

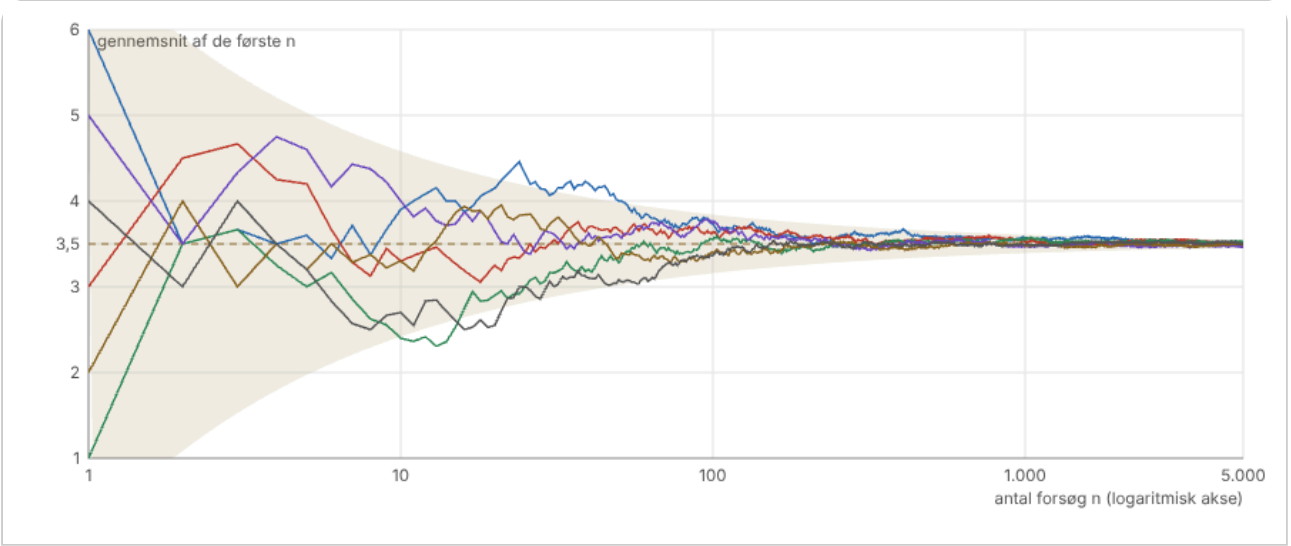


De store tals lov

Gennemsnittet af mange uafhængige udfald nærmer sig middelværdien: $\bar{X}_n = \frac{1}{n}(X_1 + \cdots + X_n) \to \mu$. Det er grunden til, at et kasino altid vinder i længden, at forsikringsselskaber kan beregne præmier, og at gentagne målinger giver et bedre resultat. Men hvor hurtigt? Spredningen af gennemsnittet er

$$\sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}}$$

For at halvere usikkerheden skal man altså måle fire gange så mange gange. Loven har en forudsætning, som er let at overse: fordelingen skal *have* en middelværdi.

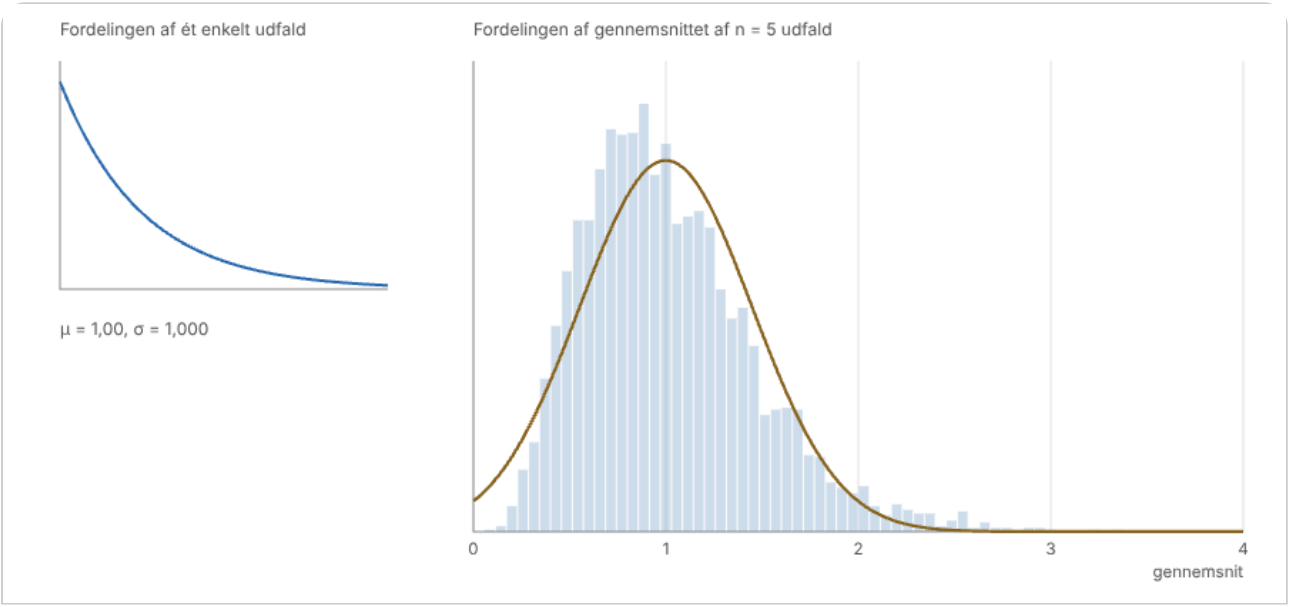


Den centrale grænseværdisætning

Den vigtigste sætning i sandsynlighedsregningen siger, at summen eller gennemsnittet af mange uafhængige tilfældige bidrag bliver normalfordelt – *næsten uanset* hvordan det enkelte bidrag er fordelt, blot det har endelig varians:

$$\bar{X}_n \approx N\left(\mu,\ \frac{\sigma^2}{n}\right) \qquad \text{for store } n$$

Laplace beviste en udgave i 1810, og Aleksandr Ljapunov gav i 1901 et stramt bevis under generelle betingelser. Sætningen forklarer, hvorfor normalfordelingen er overalt: En målefejl er summen af mange små forstyrrelser (vibrationer, temperatur, aflæsning), en persons højde er resultatet af mange gener og miljøfaktorer, og en gaspartikels hastighedskomponent er summen af utallige stød.



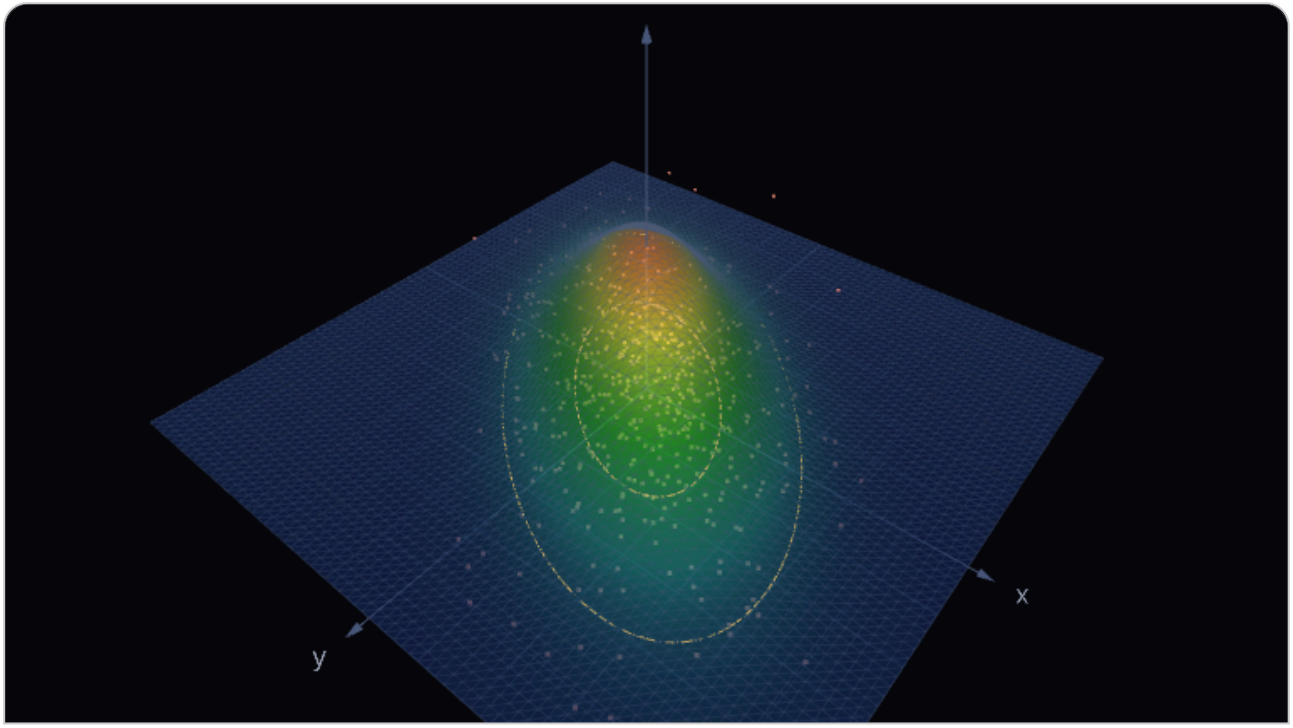
To variable og korrelation

Ofte måler man to størrelser på samme individ: højde og vægt, forældres og børns højde, temperatur og elforbrug. Den todimensionale normalfordeling har ud over middelværdier og spredninger en *korrelationskoefficient* ρ mellem −1 og 1, der måler, hvor tæt de to variable følges ad:

$$\rho = \frac{E\big[(X-\mu_x)(Y-\mu_y)\big]}{\sigma_x \sigma_y}$$

Galton opdagede i 1886, at høje forældre ganske vist får høje børn, men at børnene i gennemsnit er tættere på middelhøjden end forældrene. Han kaldte det „regression mod middelmådigheden" – i dag *regression mod middelværdien* – og det er en ren konsekvens af, at korrelationen er mindre end 1. Fænomenet narrer stadig: en sportsudøver, der har haft en usædvanlig god sæson, vil typisk klare sig dårligere næste år, uden at noget er ændret.

Den todimensionale normalfordeling (3D)

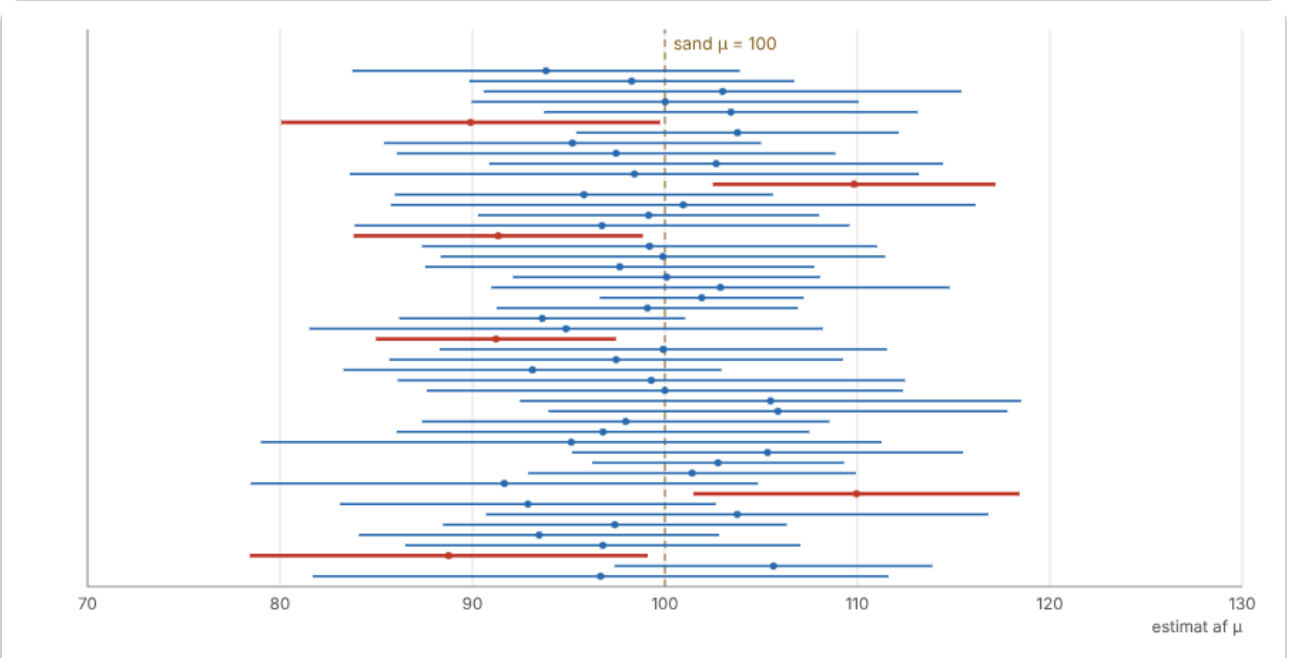


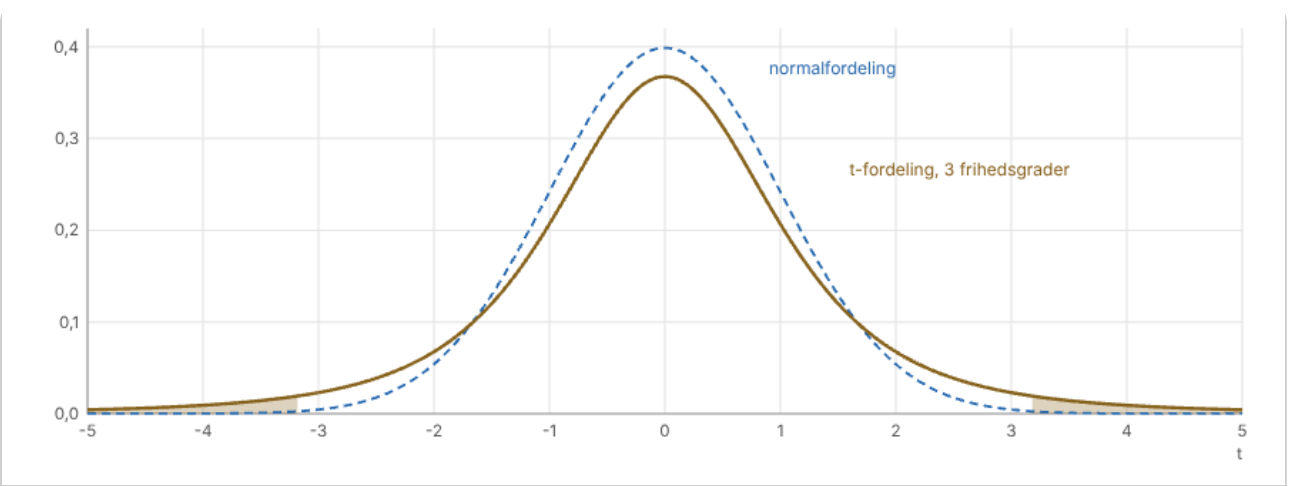
Fra stikprøve til konklusion: konfidensintervaller og t-fordelingen

I praksis kender man ikke μ; man har n målinger med gennemsnit $\bar{x}$ og stikprøvespredning s. Et *konfidensinterval* er en opskrift, der i en fastsat andel af tilfældene (typisk 95 %) giver et interval, som indeholder den sande værdi:

$$\bar{x} \pm t^* \frac{s}{\sqrt{n}}$$

Fordi s selv er usikker, skal man bruge en lidt bredere fordeling end normalfordelingen. Det fandt kemikeren William Sealy Gosset, der arbejdede for Guinness-bryggeriet i Dublin og måtte drage konklusioner fra små stikprøver af byg og humle. Han udgav resultatet i 1908 under pseudonymet „Student", fordi Guinness ikke ville afsløre over for konkurrenterne, at statistik var nyttig. Jerzy Neyman formulerede i 1937 teorien for konfidensintervaller.





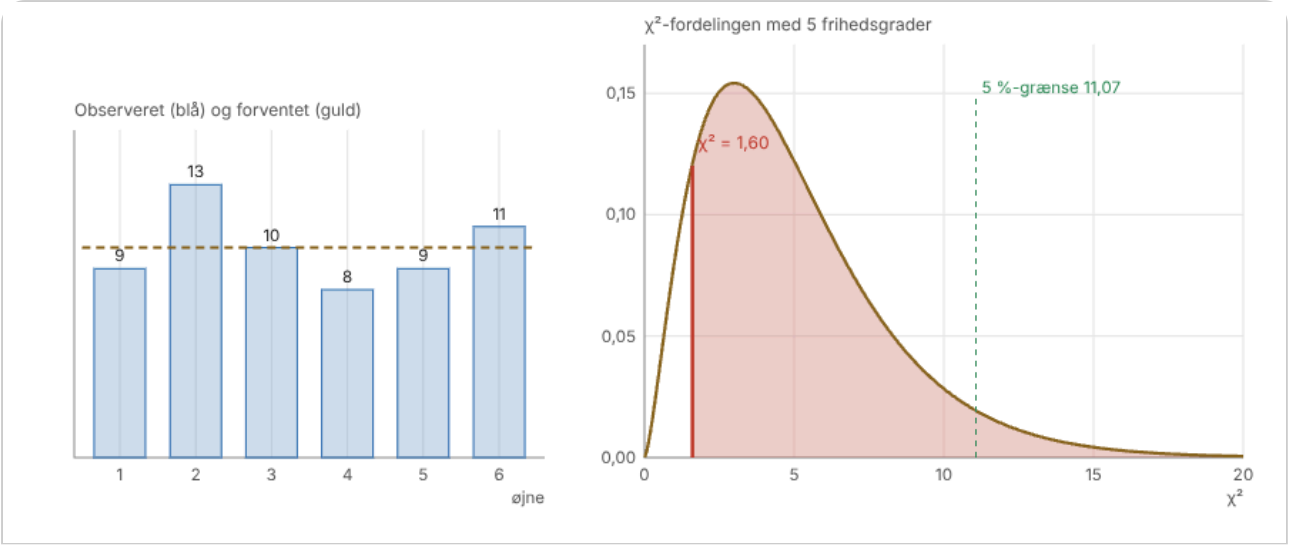
χ^2-testen: passer data til modellen?

Karl Pearson indførte i 1900 en måde at måle, hvor godt observerede antal O_i passer med de forventede E_i:

$$\chi^2 = \sum_i \frac{(O_i - E_i)^2}{E_i}$$

Hvis modellen er rigtig, følger χ^2 en kendt fordeling, χ^2-fordelingen med $k - 1$ frihedsgrader, hvor k er antallet af kategorier. *p-værdien* er sandsynligheden for at få et mindst lige så stort χ^2, hvis modellen er rigtig. Er den lille – traditionelt under 5 % – forkaster man modellen. En p-værdi er ikke sandsynligheden for, at modellen er forkert, og 5 %-grænsen er en konvention: tester man 20 sande hypoteser, vil én i gennemsnit fejlagtigt blive forkastet. I partikelfysik kræver man

derfor 5σ, dvs. $p < 3 \cdot 10^{-7}$, før man taler om en opdagelse, som da Higgs-bosonen blev fundet i 2012.



Fordelinger i fysikken

Maxwell–Boltzmann

Hver hastighedskomponent af et gasmolekyle er normalfordelt med $\sigma^2 = kT/m$, og farten følger Maxwells fordeling (1860) $f(v) \propto v^2 e^{-mv^2/2kT}$. Se Statistisk mekanik.

Boltzmann-faktoren

Sandsynligheden for en tilstand med energi E er proportional med $e^{-E/kT}$ – en eksponentialfordeling i energi. Den bestemmer kemiske reaktionshastigheder, atmosfærens tryk med højden og befolkningen af atomare niveauer.

Bose–Einstein og Fermi–Dirac

Kvantepartikler er uskelnelige. Bosoner følger $1/(e^{(E-\mu)/kT} - 1)$ – Plancks strålingslov og laseren; fermioner følger $1/(e^{(E-\mu)/kT} + 1)$ – metallers elektroner og hvide dværge.

Lorentz = Cauchy

Formen af en spektrallinje fra et atom med endelig levetid og resonanskurven for en svingning er en Cauchy-fordeling. Dens manglende middelværdi er grunden til, at man angiver linjens halvværdibredde i stedet for en spredning.

Lognormal

Når tilfældige bidrag ganges i stedet for at lægges sammen, bliver logaritmen normalfordelt: kornstørrelser i sand og støv, dråbestørrelser i regn, indkomster og aktiekurser.

Potenslove

Jordskælv følger Gutenberg–Richters lov: for hvert trin op på Richterskalaen er der omkring ti gange færre. Tunge haler af denne type findes også hos meteoritters størrelser, solflares og byers indbyggertal – og de gør gennemsnit upålidelige, som for Cauchy-fordelingen.

Læs mere

- David Freedman, Robert Pisani og Roger Purves: *Statistics* (4. udg., Norton 2007) – den klareste indføring uden tunge formler
- Sheldon Ross: *A First Course in Probability* (Pearson, mange udgaver)
- Philip R. Bevington og D. Keith Robinson: *Data Reduction and Error Analysis for the Physical Sciences* (3. udg., McGraw-Hill 2003)
- Stephen M. Stigler: *The History of Statistics* (Harvard 1986)
- David Salsburg: *The Lady Tasting Tea – How Statistics Revolutionized Science in the Twentieth Century* (Freeman 2001)
- Siderne om statistisk mekanik og kernefysik

mhgfysik.dk · Michael H. Grant, lektor emeritus i fysik & matematik · Indholdet må genbruges under CC BY 4.0 med kildeangivelse. · Til forsiden · Interaktive figurer: mhgfysik.dk/statistiske-fordelinger.html